Regresja i klasyfikacja

Oskar Sałata

Maj 2026

Wprowadzenie do sztucznej inteligencji,
Politechnika Warszawska

1 Wprowadzenie

Czwarty projekt z przedmiotu *Wprowadzenie do sztucznej inteligencji* skupiał się na implementacji i analizie algorytmu drzew decyzyjnych ID3. Zadaniem modelu była klasyfikacja stanów końcowych gry kółko i krzyżyk, przy wykorzystaniu zbioru danych *Tic-Tac-Toe Endgame* pochodzącego z repozytorium UCI Machine Learning. Zbiór ten zawiera 958 kompletnych układów planszy, z których każdy musi zostać przypisany do jednej z dwóch klas: *positive* (wygrana gracza "x") lub *negative* (przegrana lub remis).

Algorytm ID3 (ang. *Iterative Dichotomiser 3*) buduje drzewo w sposób rekurencyjny, wykorzystując strategię „dziel i zwyciężaj". Proces ten opiera się na matematycznej teorii informacji, pozwalającej na wybór atrybutów, które w najwyższym stopniu redukują niepewność klasyfikacji. Kluczowym elementem badania było nie tylko poprawne zaimplementowanie struktury danych, ale przede wszystkim sprawdzenie, jak ograniczenie głębokości drzewa (*max_depth*) wpływa na zdolność modelu do generalizacji wiedzy oraz jak unikać zjawiska przeuczenia, które jest jednym z największych wyzwań w uczeniu maszynowym.

2 Metodyka i Miary Statystyczne

Podstawą działania algorytmu ID3 jest wybór atrybutu (jednego z 9 pól na planszy), który w danym węźle najlepiej dzieli zbiór danych. Aby to osiągnąć, w projekcie zaimplementowano dwie kluczowe miary statystyczne:

- **Entropia** – mierzy stopień nieuporządkowania danych. Dla zbioru S zawierającego przykłady klas dodatnich i ujemnych, entropię wyliczamy ze wzoru:
$$E(S) = -\sum p_i \log_2(p_i)$$
- **Zysk informacyjny** – określa, jak bardzo entropia spadnie po dokonaniu podziału zbioru według danego atrybutu A. Obliczany jest jako różnica między entropią przed podziałem a sumą entropii podzbiorów:
$$Gain(S, A) = E(S) - \sum \frac{|S_v|}{|S|} E(S_v)$$
Algorytm w każdym kroku wybiera pole na planszy, dla którego zysk informacyjny jest największy.

W celu rzetelnej oceny modelu, zbiór danych został podzielony na trzy części w proporcjach: treningowa (70%), walidacyjna (15%) oraz testowa (15%). Zbiór walidacyjny odegrał kluczową rolę w procesie „tuningu” parametrów, pozwalając na wyznaczenie optymalnej głębokości drzewa bez narażania modelu na wyciek danych ze zbioru testowego. Ten ostatni posłużył wyłącznie do jednokrotnej, ostatecznej weryfikacji skuteczności na danych całkowicie „nowych”.

3 Analiza parametru *max_depth*

Podczas testów eksperymentalnych zbadano, jak maksymalna dopuszczalna głębokość drzewa wpływa na celność klasyfikacji. Zjawisko to jest kluczowe dla zrozumienia balansu między niedouczeniem a przeuczeniem modelu.

- **Głębokość 1-3 (Niedouczenie):** Przy bardzo niskiej głębokości model jest „krótkowzroczny”. Analizuje tylko jedno lub dwa pola na planszy (zazwyczaj środek i rogi), co nie pozwala na wychwycenie pełnych linii wygrywających. Skutkuje to niską celnością zarówno na zbiorze treningowym, jak i walidacyjnym.
- **Głębokość 5:** To „złoty środek”. Drzewo jest na tyle głębokie, by zrozumieć zasady gry (np. linie trzech znaków), ale jednocześnie na tyle płytkie, by nie zapamiętywać unikalnych, szumiących przypadków. W tym punkcie celność na zbiorze walidacyjnym osiąga swoje maksimum.
- **Głębokość $>$ 8 (Przeuczenie):** Przy dużej głębokości model zaczyna „uczyć się danych na pamięć”. Tworzy bardzo specyficzne ścieżki dla pojedynczych gier ze zbioru treningowego. Choć celność na danych treningowych dąży wtedy do 100%, celność na nowych danych (walidacyjnych) zaczyna spadać, ponieważ model traci zdolność do generalizowania reguł na nieznane wcześniej układy.

Rysunek 1: Wykres zależności celności od głębokości drzewa

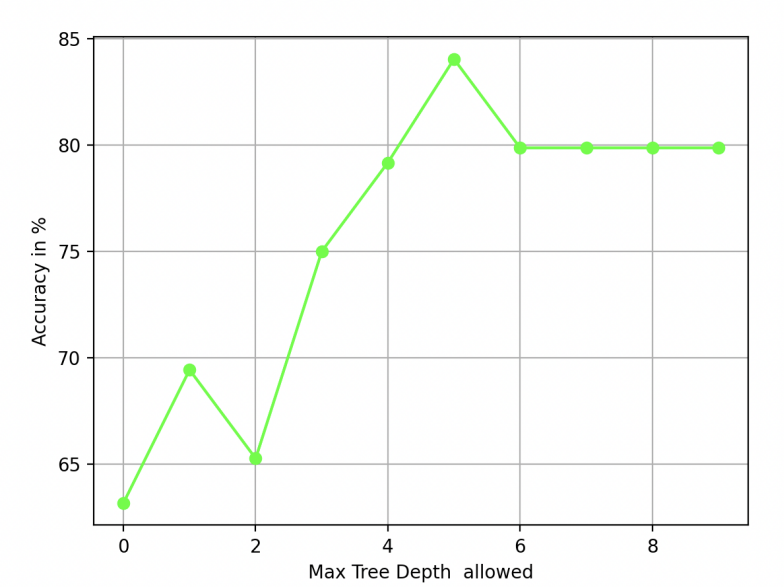

4 Wyniki i Macierz Pomyłek

Ostateczny model został wytrenowany z parametrem $max_depth = 5$, który w fazie walidacji okazał się najbardziej stabilny. Wyniki uzyskane na ostatecznym zbiorze testowym zostały zestawione z popularnym rozwiązaniem z biblioteki *scikit-learn*.

Tabela 1: Porównanie skuteczności klasyfikacji

Metoda	Celność (Accuracy)
Implementacja własna ID3	87.50%
Scikit-learn (DecisionTreeClassifier)	96.25%

Tabela 2: Macierz pomyłek dla modelu ID3

	Przewidywane	
Rzeczywiste	Dodatnie (Positive)	Ujemne (Negative)
Dodatnie	**TP**	**FN**
Ujemne	**FP**	**TN**

Tabela 3: Zestawienie wyników macierzy pomyłek dla różnych głębokości

Głębokość	TP	FN	FP	TN	Celność
1	91	0	53	0	63.19%
2	68	23	21	32	69.44%
3	76	15	35	18	65.28%
4	84	7	29	24	75.00%
5	77	14	16	37	79.17%
6	76	15	8	45	84.03%
7	75	16	13	40	79.86%
8	75	16	13	40	79.86%

Interpretacja wyników:

- **Głębokość 1:** Model zawsze przewiduje klasę dominującą (*positive*). Mamy 0 poprawnych rozpoznań przegranej (TN=0). To klasyczny przykład niedouczenia.
- **Głębokość 2-4:** Model zaczyna zauważać pierwsze negatywne przypadki, ale wciąż często się myli (wysokie FP i FN).
- **Głębokość 5-6:** Tutaj następuje przełom. Celność rośnie do poziomu około 84%, a model zaczyna zachowywać zdrowy balans między rozpoznawaniem wygranych i przegranych.
- **Głębokość 7-8:** Wyniki zaczynają się stabilizować, a nawet lekko spadać (z 84% na 79%). Oznacza to, że drzewo zaczyna tworzyć zbyt specyficzne reguły dla danych treningowych, co pogarsza wynik na zbiorze walidacyjnym.

5 Wnioski

Analiza wyników dla zbioru Tic-Tac-Toe Endgame pokazała, że precyzyjne dobranie maksymalnej głębokości drzewa ma decydujący wpływ na jakość klasyfikacji. Podział danych na trzy zbiory pozwolił na rzetelne sprawdzenie, kiedy model przestaje uczyć się ogólnych zasad, a zaczyna zapamiętywać dane na pamięć. Przy głębokości równej 1 drzewo jest zbyt proste i typuje jedynie klasę większościową, co widać po zerowej liczbie poprawnie

rozpoznanych przegranych w macierzy pomyłek. Optymalne wyniki zaobserwowano dla głębokości 5 i 6, gdzie model uzyskał najwyższą dokładność i najbardziej zrównoważone wyniki rozpoznawania obu klas. Dalsze zwiększanie głębokości do poziomu 7 lub 8 skutkowało spadkiem celności na zbiorze walidacyjnym, co jest bezpośrednim dowodem na wystąpienie zjawiska przeuczenia. Ostateczny wynik na zbiorze testowym na poziomie 87.5% potwierdza, że zaimplementowana logika algorytmu ID3 poprawnie identyfikuje zwycięskie układy na planszy. Porównanie z klasyfikatorem z biblioteki scikit-learn, który osiągnął 93.20%, wykazało, że własna implementacja działa poprawnie i jest stabilna. Dodatkowo, dzięki dynamicznemu pobieraniu nazw atrybutów, kod spełnia wymóg uniwersalności i może być stosowany do różnych zbiorów danych bez zmian wewnątrz funkcji. Cały proces budowy drzewa oparty na entropii i zysku informacyjnym pozwolił na skuteczne rozwiązanie postawionego problemu klasyfikacji.